

## Глава 3

# Функции риска, функции потерь. Байесовские оценки. Минимаксные оценки

### 3.1 Базовая часть

#### 3.1.1 Риски и потери

##### Определение функций риска и потерь

Поговорив об асимптотических свойствах оценок, перейдем к оцениванию на выборках фиксированного размера. Зачастую на практике мы сталкиваемся с тем, что оценивание производится с известной ценой за ошибку. В общем случае у нас задана функция потерь  $L(\theta, x)$ , которая отражает, сколько мы теряем, если настоящее значение параметра  $\theta$ , а наша оценка  $x$ .

Будем считать, что  $\Theta = \mathbb{R}^k$ .

**Определение 1.** Функцией потерь называют такую функцию  $L : \mathbb{R}^k \times \mathbb{R}^k \rightarrow \mathbb{R}^+$ , что  $L(\theta, \theta) = 0$ .

Мы будем подставлять вместо  $x$  некоторые оценки  $\hat{\theta}(X_1, \dots, X_n)$ , где  $X_i$  — выборка. Таким образом, наши потери будут случайной величиной, которую мы, в некотором роде, хотели бы минимизировать. Со случайной потерей работать неудобно, поэтому рассматривают ее среднее.

**Определение 2.** Функцией риска называют отображение  $R : \mathbb{R}^k \times \mathcal{L} \rightarrow \mathbb{R}^+$ , заданное соотношением

$$R(\theta, \hat{\theta}) = \mathbf{E}_{\theta} \left( L \left( \theta, \hat{\theta}(X_1, \dots, X_n) \right) \right).$$

Здесь  $\mathcal{L}$  — множество оценок  $\hat{\theta}$ , то есть измеримых отображений из множества выборок  $\mathcal{X}$  в  $\mathbb{R}^+$ .

Функция потерь получает на вход  $\theta$  и число  $\hat{\theta}$  (то есть значение статистики на данной реализации). Функция риска получает на вход  $\theta$  и вид оценки  $\hat{\theta}$  (то есть форму зависимости  $\hat{\theta}$  от  $X_1, \dots, X_n$ ).

**Пример 1.** Пусть владелец булочной оценивает количество людей  $\theta$ , которые придут к нему сегодня. Если его оценка  $x$  окажется заниженной, то он потеряет  $c_1 \cdot (\theta - x)$  денег, где  $c_1$  — выгода, получаемая владельцем с каждой булки. Если завышенной, то он потеряет  $c_2 \cdot (x - \theta)$ , где  $c_2$  — цена производства одной булки. При этом он будет использовать некоторую оценку  $\hat{\theta}$ , связанную со статистикой предыдущих дней, поэтому его потери будут случайными, зависящими от  $\theta$  и от выборки. Для пекаря его потери — ключевая характеристика метода оценивания, превалирующая над ”хорошими” свойствами оценок.

Предположим, что  $X_i$  имеют нормальное распределение со средним  $\theta$  и дисперсией 1. Тогда у оценки  $\hat{\theta} = X_1$  функция риска будет равна

$$c_2 \mathbf{E}(X_1 - \theta) I_{X_1 > \theta} + c_1 \mathbf{E}(\theta - X_1) I_{X_1 < \theta} = \frac{c_1 + c_2}{\sqrt{2\pi}} \int_0^{\infty} x e^{-x^2/2} dx = \frac{c_1 + c_2}{\sqrt{2\pi}}.$$

## Три классических функции потерь

- В одномерном случае часто рассматривают квадратичную функцию потерь

$$L(\theta; x) = (x - \theta)^2.$$

В многомерном ее аналогом может быть  $L^2$  потеря  $\|\theta - x\|^2$  или более общая конструкция

$$\|\theta - x\|_C^2 = (\theta - x)C(\theta - x)^T,$$

где  $C$  — некоторая заданная матрица.

- Вторым популярным вариантом является абсолютная потеря

$$L(\theta; x) = |x - \theta|.$$

В многомерном случае можно рассматривать взамен  $L^1$  потерю  $\sum_{i=1}^k |x_i - \theta_i|$  или более общая взвешенная конструкция

$$\sum_{i=1}^k c_i |x_i - \theta_i|.$$

- Третьим популярным вариантом (преимущественно в случае, если множество значений  $\theta$  не более чем счетно) является дискретная потеря

$$L(\theta; x) = I_{\theta \neq x}.$$

## О важности квадратичной функции потерь

Зачастую рассматриваются функции потерь, зависящие только от разности  $\theta$  и  $\hat{\theta}$ , как это было в примере 1 или в трех случаях выше. В таком случае особенную роль играет квадратичная функция потерь  $L(\theta, x) = (\theta - x)^2$ . Важность ее вытекает из следующего соображения — любая гладкая дважды дифференцируемая функция потерь  $L$ , зависящая только от  $\theta - x$ , разлагается в ряд Тейлора

$$L(\theta - x) = a + b(\theta - x) + c(\theta - x)^2 + \varepsilon,$$

где  $a = 0$ ,  $b = 0$  из условий неотрицательности и равенства 0 в точке 0. В свою очередь  $\varepsilon$  по порядку есть  $o((\theta - x)^2)$ , то есть при близко оценивающих  $\theta$  оценках (например, при состоятельных  $\hat{\theta}$  и больших  $n$ ) функция риска будет вести себя как  $c(\theta - x)^2$ .

В случае, если  $\theta$  — векторный параметр, аналогичным образом можно использовать  $\|\theta - x\|_C^2$ , которая также дает основной член асимптотики.

## Квадратичная потеря и дисперсия

Для квадратичной функции потерь функция риска будет просто равна  $\mathbf{E}_\theta(\hat{\theta} - \theta)^2$ . В частности, для несмещенной оценки это будет  $\mathbf{D}_\theta \hat{\theta}$ . Для смещенных оценок в силу соотношения

$$\mathbf{E}(X - a)^2 = \mathbf{E}(X - \mathbf{E}X + \mathbf{E}X - a)^2 = \mathbf{E}(X - \mathbf{E}X)^2 + (\mathbf{E}X - a)^2 + 2(\mathbf{E}X - a)\mathbf{E}(X - \mathbf{E}X) = \mathbf{D}X + (\mathbf{E}X - a)^2,$$

риск для квадратичной функции потерь есть  $\mathbf{D}_\theta \hat{\theta} + (\mathbf{E}_\theta \hat{\theta} - \theta)^2$ .

### 3.1.2 Три подхода к минимизации риска

#### Основной подход

Мы хотели бы выбрать оценку так, чтобы минимизировать функцию риска. Однако, функция риска при каждой оценке будет зависеть от  $\theta$  и потому необходимо конкретизировать, как мы будем выбирать "меньшую" среди функций. Здесь имеются три основных подхода:

1. Ограничение рассматриваемых оценок. Если мы ограничим множество рассматриваемых оценок до какого-то класса, то может оказаться, что в этом классе одна из функций риска лежит ниже всех остальных.

**Определение 3.** Оценка  $\hat{\theta}$  называется равномерно наиболее мощной в классе оценок  $K \subset \mathcal{L}$ , если  $\hat{\theta} \in K$  и  $R(\theta, \hat{\theta}) \leq R(\theta, \hat{\theta}_1)$  при всех  $\theta \in \Theta$  и всех  $\hat{\theta}_1 \in K$ .

Мы уже искали такие оценки для квадратичного риска на первом семинаре. Более общие подходы к таким задачам мы рассмотрим позднее.

2. Минимаксный подход. Будем использовать "подход пессимиста". Давайте предположим, что по закону подлости наверняка выпадет тот самый параметр при котором риск наибольший. Следовательно, наша задача — минимизировать максимум функции риска.

**Определение 4.** Оценка  $\hat{\theta}$  такая, что  $\max_{\theta} R(\theta, \hat{\theta}) \leq \max_{\theta} R(\theta, \hat{\theta}_1)$  для любой оценки  $\hat{\theta}_1$  называется *минимаксной*.

Методы построения таких оценок вынесены в факультатив.

3. Байесовский подход. Будем считать, что мы знаем функцию  $\pi(\theta)$  на  $\Theta$ , описывающую частоту встречаемости параметров  $\theta$  в окружающей реальности. Тогда осмысленно минимизировать средний риск (его называют байесовским)

$$R(\hat{\theta}) = \int_{\Theta} R(\theta; \hat{\theta}) \pi(\theta) d\theta.$$

**Определение 5.** Оценка  $\hat{\theta}$  такая, что  $R(\hat{\theta}) \leq R(\hat{\theta}_1)$  для любой оценки  $\hat{\theta}_1$  называется *байесовской*.

## Примеры

**Пример 2.** Рассмотрим оценку  $\bar{X}$  в схеме Бернулли. Как мы докажем чуть позже это оценка с наименьшей возможной дисперсией среди несмещенных. Значит в классе несмещенных оценок  $\bar{X}$  имеет риск для квадратичной функции потерь, то есть равномерно наиболее мощна. Ее риск при этом равен  $\theta(1 - \theta)/n$ .

При этом среди всех оценок она не является равномерно наиболее мощной, например, при  $\theta = 1/2$  оценка  $\hat{\theta}(X_1, \dots, X_n) = 1/2$  будет иметь нулевой риск, а  $\bar{X}$  — ненулевой.

**Пример 3.** Для схемы Бернулли минимаксной оценкой, как следует из одной из факультативных задач, будет вовсе не  $\bar{X}$ , а смещенная оценка

$$\tilde{\theta}(X_1, \dots, X_n) = \bar{X} + (1/2 - \bar{X}) \frac{1}{1 + \sqrt{n}},$$

называемая оценкой Ходжеса-Лемана. Сравним эти оценки для выборки размера 1. Для квадратичной функции потерь риск для первой есть  $\theta(1 - \theta)$ . Для второй

$$\left(1 + \frac{-1/2 - \theta}{2}\right)^2 \theta + \left(\frac{1/2 - \theta}{2}\right)^2 (1 - \theta) = \left(\frac{3}{4} - \theta\right)^2 \theta + \left(\frac{1}{4} - \theta\right)^2 (1 - \theta) = \frac{1}{16}.$$

Очевидно, что в первом случае максимум  $1/4$ , что больше  $1/16$ .

**Пример 4.** Приведем пример использования байесовского подхода. Представим себе, что мы хотим провести десять испытаний Бернулли и на основе их решить, готовы ли мы заключить пари, что из следующих 1000 испытаний будет не больше 100 успехов. Проведя 10 испытаний, мы видим в них десять успехов. Это описание дает жесткое описание математическому эксперименту и, по идее, мы должны во всех реализациях такой задачи получить одну и ту же оценку параметра  $\theta$  и сделать один и тот же вывод. Давайте представим себе три эксперимента. В первом из них ваш знакомый угадывает на орла или на решку упадет монета (монету подбрасываете вы, она симметричная и заведомо никаких

мошенничеств нет). Во втором пожилая леди по вкусу угадывает, что раньше положили в чай — лимон или сахар. В третьем музыкальный эксперт определяет по короткому отрывку, кому принадлежит произведение — Шуману или Шуберту. Неужели в жизни вы приняли бы одно и то же решение во всех трех экспериментах?

Различные взгляды на эти три схемы Бернулли связаны с тем, что на практике у вас есть изначальное представление о том, насколько часто может встречаться тот или иной параметр. Это может быть выражено, например, в виде плотности распределения (или в дискретном случае самого распределения) параметра  $\theta$  по множеству  $\Theta$ . Ниже мы будем использовать термин "плотность" для обоих этих случаев. Плотность  $\pi(\theta)$  может появляться как обобщение прошлых опытов (например, фармацевтическая кампания, выпуская новый препарат, может оценить его продаваемость по прошлым продажам других препаратов) или же обобщать наши представления о том, с какой частотой встречается тот или иной параметр. Такая плотность называется априорной, то есть доопытной. В нашем случае, для первого варианта можно предположить распределение с сильным пиком в  $1/2$ , скажем, напоминающее нормальное распределение с очень маленькой дисперсией. Для третьего, если есть мнение, что угадывающий действительно эксперт, можно взять плотность с большими значениями в области  $[3/4, 1]$ . Для второго в силу неизведанности этого явления, поставить равномерную на  $[0, 1]$  плотность.

Итак, в байесовском случае мы сравниваем не все значения функции риска, а сравниваем функции риска с учетом вероятности параметра  $\theta$  (скажем, пекарь в примере 1, не будет сильно печалиться из-за оценки, приносящей большие потери в случае, когда число клиентов за день  $\theta = 6 \cdot 10^9$ ). Это позволяет эффективно использовать результаты прошлых опытов.

Однако, метод уязвим за счет неоднозначности определения априорной плотности. Скажем, кто-то может заявить, что эксперты, отличающие Шумана от Шуберта — это миф и поставит им в соответствие плотность, которую мы предложили для случая 1, зато экстрасенсы встречаются достаточно часто и у человека, угадывающего результат выпадения монеты, априорная плотность имеет форму, предложенную нами для случая 3, а понять, что первым положили в чай — сахар или лимон, может вообще каждый с вероятностью 1.

Не стоит смущаться тем, что параметр  $\theta$ , как мы говорили прежде, некоторая неизвестная, но фиксированная величина. Это не мешает считать, что он явился результатом некоторого случайного опыта. Оценивая расстояние между Нью-Йорком и Москвой, мы как будто предполагаем, что Нью-Йорк был построен на случайном расстоянии от Москвы и, по стечению обстоятельств, попал именно туда, куда попал.

### 3.1.3 Построение байесовской оценки

#### Апостериорная плотность

Итак, имея некоторые доопытные представления о распределении параметра, мы должны скорректировать их с учетом выборки. Иначе говоря, мы должны посчитать условную плотность (дискретное распределение) параметра  $\theta$  при условии наблюдения выборки  $x$ .

В случае дискретных  $\Theta$ ,  $X$  из формулы Байеса вытекает соотношение

$$f_{\theta|X_1, \dots, X_n}(u|x_1, \dots, x_n) = P(\theta = u|X_1 = x_1, \dots, X_n = x_n) = \frac{P_u(X_1 = x_1) \dots P_u(X_n = x_n) \pi(u)}{\sum_{\theta \in \Theta} P_{\theta}(X_1 = x_1) \dots P_{\theta}(X_n = x_n) \pi(\theta)}.$$

Распределение  $f_{\theta|X_1, \dots, X_n}$  называют апостериорным распределением параметра  $\theta$ .

В случае абсолютно-непрерывных распределений плотностью  $Y|X$  называют

$$f_{Y|X}(y|x) = \frac{f_{Y,X}(y, x)}{f_X(x)} = \frac{f_{X|Y}(x|y) f_Y(y)}{\int_{\mathbb{R}} f_{X,Y}(x, v) dv} = \frac{f_{X|Y}(x|y) f_Y(y)}{\int_{\mathbb{R}} f_{X|Y}(x|v) f_Y(v) dv}$$

Таким образом, апостериорную плотность параметра  $\theta$  в абсолютно-непрерывном случае естественно задавать соотношением

$$f_{\theta|X_1, \dots, X_n}(u|x_1, \dots, x_n) = \frac{f_u(x_1) \dots f_u(x_n) \pi(u)}{\int_{\Theta} f_v(x_1) \dots f_v(x_n) \pi(v) dv}.$$

**Пример 5.** Для второго эксперимента примера 1 мы выбрали равномерную на  $[0,1]$  априорную плотность и наблюдаем успехов из 10 опытов. Для схемы Бернулли с равномерно распределенным параметром апостериорная плотность имеет вид

$$f_{\theta|X_1, \dots, X_n}(u|x_1, \dots, x_n) = \frac{u^{\sum x_i} (1-u)^{n-\sum x_i} I_{u \in [0,1]}}{\int_0^1 u^{\sum x_i} (1-u)^{n-\sum x_i} du} = \frac{u^{\sum x_i} (1-u)^{n-\sum x_i} I_{u \in [0,1]}}{B(1 + \sum x_i, n + 1 - \sum x_i)}.$$

В нашем случае имеем  $B(11, 1) = \frac{\Gamma(1)\Gamma(11)}{\Gamma(12)} = 1/11$ , то есть плотность будет иметь вид  $11u^{10}I_{u \in [0,1]}$ . Как видим по рисунку, плотность "покосилась" направо.

В случае произвольных наблюдений  $x_1, \dots, x_n$  апостериорная плотность имела бы вид

$$f_{\theta|X_1, \dots, X_n}(u|x_1, \dots, x_n) = \frac{u^{x_1 + \dots + x_n} (1-u)^{n-x_1 - \dots - x_n}}{\int_0^1 u^{x_1 + \dots + x_n} (1-u)^{n-x_1 - \dots - x_n} du}.$$

Отметим полезное соображение — можно не высчитывать знаменатель, а лишь заметить, что он не зависит от  $u$ , то есть плотность имеет вид

$$Cu^a(1-u)^b I_{u \in [0,1]},$$

где  $a = x_1 + \dots + x_n$ ,  $b = n - x_1 - \dots - x_n$ ,  $C$  — некоторая константа (то есть не зависящая от  $u$  величина, но при этом зависящая от  $x_1, \dots, x_n$ ). Мы знаем распределение такого вида — это бета-распределение, в котором  $C = 1/B(a+1, b+1)$ . Но плотности не могут отличаться в константу раз, поэтому апостериорная плотность есть плотность бета-распределения с параметрами  $x_1 + \dots + x_n + 1, n - x_1 - \dots - x_n + 1$ .

## Сопряженные распределения

Наиболее удобно работать с байесовскими оценками в том случае, когда апостериорная плотность или апостериорное распределение будет того же типа, что априорное (например, и то, и то распределение будет нормальным, но с разными параметрами). Такое априорное распределение называется сопряженным (в иностранной литературе conjugate prior). Список популярных сопряженных распределений можно найти по ссылке

## Байесовская оценка для квадратичной потери

Как же найти байесовскую оценку? Ответы можно получить для различных видов функции потерь. Начнем с классической ситуации квадратичной потери. В этом случае байесовская оценка есть математическое ожидание величины с апостериорной плотностью:

**Теорема 1.** Для квадратичной функции потерь байесовская оценка имеет вид

$$\theta^*(x_1, \dots, x_n) = \frac{\int_{\Theta} \theta f_{\theta}(x_1) \dots f_{\theta}(x_n) \pi(\theta) d\theta}{\int_{\Theta} f_{\theta}(x_1) \dots f_{\theta}(x_n) \pi(\theta) d\theta}.$$

При этом предполагается конечность величины в числителе и положительность и конечность величины в знаменателе.

При этом риск (не байесовский, а обычный) такой оценки будет равен математическому ожиданию от дисперсии апостериорного распределения (дисперсия апостериорного распределения есть функция выборки, а математическое ожидание берется по плотности  $f_{\theta}$ ).

## Байесовская оценка для абсолютной и дискретной потери

Сформулируем еще две теоремы (их доказательства отнесены в факультативные задачи) о виде байесовской оценки для других видов функции потерь:

**Теорема 2.** Пусть функция потерь абсолютная:  $L(\theta, x) = |\theta - x|$ . Назовем апостериорной функцией распределения функцию

$$\tilde{F}(\theta|x_1, \dots, x_n) = \frac{\int_{-\infty}^{\theta} f_u(x_1) \dots f_u(x_n) \pi(u) du}{\int_{-\infty}^{\infty} f_u(x_1) \dots f_u(x_n) \pi(u) du} = \int_{-\infty}^{\theta} f_{\theta|X_1, \dots, X_n}(u|x_1, \dots, x_n) du.$$

Пусть  $\tilde{F}$  — непрерывная функция. Тогда байесовской оценкой  $\hat{\theta}$  будет медиана  $\tilde{F}^{-1}(1/2)$ , т.е.  $\tilde{F}(\hat{\theta}(x_1, \dots, x_n)|x_1, \dots, x_n) = 1/2$ .

**Теорема 3.** Пусть  $\Theta = \{\theta_1, \dots, \theta_k\}$ , функция потерь дискретная:  $L(\theta, x) = I_{\theta \neq x}$ . Иначе говоря, мы решаем задачу классификации — если мы угадываем  $\theta$ , то ничего не теряем, если не угадываем — теряем 1. Тогда оценки будут принимать только значения  $\theta_1, \dots, \theta_k$ . Байесовской оценкой при этом будет  $\hat{\theta}(x_1, \dots, x_n)$ , равная  $\theta_i$  при тех  $x_1, \dots, x_n$ , при которых

$$\mathbf{P}(\theta = \theta_i | X_1 = x_1, \dots, X_n = x_n) > \mathbf{P}(\theta = \theta_j | X_1 = x_1, \dots, X_n = x_n), \quad \forall j \neq i.$$

Это вполне естественно — мы выбираем то  $\theta$ , которое апостериорно наиболее вероятно.

### Пример

**Пример 6.** Таким образом, для квадратичного риска в схеме Бернулли байесовской оценкой при равномерной априорной плотности будет

$$\frac{B(2 + \sum x_i + 2, n + 1 - \sum x_i)}{B(1 + \sum x_i, n + 1 - \sum x_i)} = \frac{\Gamma(2 + \sum x_i) \Gamma(n + 2)}{\Gamma(1 + \sum x_i) \Gamma(n + 3)} = \frac{1 + \sum x_i}{n + 2}$$

В случае примера 5 она примет значение  $11/12 \approx 0.92$ . Для абсолютного риска в том же примере я должен был найти апостериорную функцию распределения ( $x^{11}$  при  $x \in [0, 1]$ ) и найти ее медиану из соотношения  $\hat{\theta}^{11} = 1/2$ , откуда  $\hat{\theta} = 2^{-1/11} \approx 0.94$ .

## 3.2 Факультатив

### 3.2.1 Доказательство теоремы 1

*Доказательство.* Доказательство достаточно просто:

$$\begin{aligned} R(\hat{\theta}) &= \int_{\Theta} R(\theta, \hat{\theta}) \pi(\theta) d\theta = \int_{\Theta} \int_{R^n} (\hat{\theta} - \theta)^2 f_{\theta}(x_1) \dots f_{\theta}(x_n) dx_1 \dots dx_n \pi(\theta) d\theta = \\ &= \int_{R^n} \int_{\Theta} (\hat{\theta}(x_1, \dots, x_n) - \theta)^2 \pi(\theta) f_{\theta}(x_1) \dots f_{\theta}(x_n) d\theta dx_1 \dots dx_n. \end{aligned}$$

Внутренний интеграл есть

$$\begin{aligned} \hat{\theta}^2(x_1, \dots, x_n) \int_{\Theta} f_{\theta}(x_1) \dots f_{\theta}(x_n) \pi(\theta) d\theta - 2\hat{\theta}(x_1, \dots, x_n) \int_{\Theta} \theta f_{\theta}(x_1) \dots f_{\theta}(x_n) \pi(\theta) d\theta + \\ \int_{\Theta} \theta^2 f_{\theta}(x_1) \dots f_{\theta}(x_n) \pi(\theta) d\theta = a\hat{\theta}^2 + b\hat{\theta} + c. \end{aligned}$$

При каждом наборе  $x_1, \dots, x_n$  он будет достигать минимума при  $\hat{\theta}(x_1, \dots, x_n)$ , являющимся вершиной соответствующей параболы, то есть  $-b/(2a)$ . Значит и максимум интеграла будет достигнут при такой  $\hat{\theta}$ . Аналогичным образом можно решать задачи для неквадратичного риска.  $\square$

### 3.2.2 Минимаксные оценки

Для построения минимаксной оценки удобно использовать следующие несложные результаты

**Теорема 4.** Если оценка  $\hat{\theta}$  имеет постоянный по  $\theta$  риск и найдется такая априорная плотность  $\pi$ , что оценка  $\hat{\theta}$  — байесовская, то  $\hat{\theta}$  — минимаксная оценка.

*Доказательство.* Пусть  $\hat{\theta}$  не минимаксна. Тогда найдется такая  $\hat{\theta}_1$ , что

$$\sup_{\theta \in \Theta} R(\theta; \hat{\theta}_1) < \sup_{\theta \in \Theta} R(\theta; \hat{\theta}) = R(\theta, \hat{\theta}).$$

Но тогда при всех  $\theta$  справедливо неравенство

$$R(\theta; \hat{\theta}_1) < R(\theta, \hat{\theta}).$$

Но поскольку оценка  $\hat{\theta}$  байесовская,

$$\int_{\Theta} R(\theta, \hat{\theta}) \pi(\theta) d\theta \leq \int_{\Theta} R(\theta, \hat{\theta}_1) \pi(\theta) d\theta.$$

Эти два неравенства противоречат друг другу. Следовательно,  $\hat{\theta}$  минимаксна. □

Таким образом, удачно подобрав априорную плотность, мы можем доказывать минимаксность оценки с постоянным риском. Более того, справедлива и более общая теорема:

**Теорема 5.** Если оценка  $\hat{\theta}$  имеет постоянный по  $\theta$  риск и найдется такая последовательность априорных плотностей  $\pi_n$ , что  $R(\hat{\theta}, \theta) \leq \liminf_{n \rightarrow \infty} R(\hat{\theta}_n)$  при всех  $\theta$ , где  $\hat{\theta}_n$  — байесовские с  $\pi_n$ ,  $R$  — их байесовский риск, то  $\hat{\theta}$  — минимаксная оценка.

Доказательство практически аналогично.